

**KLASIFIKASI RISIKO PENYAKIT DEMAM BERDARAH
DENGUE (DBD) DENGAN ALGORITMA *K-NEAREST
NEIGHBORS* (KNN)**



Disusun oleh:

Rezki Nur Vidhiyansyah	(2211102207)
Alvi Anggraeni	(2211102209)

**KELAS S1-IF-10-5
PROGRAM STUDI TEKNIK INFORMATIKA
FAKULTAS INFORMATIKA
UNIVERSITAS TELKOM PURWOKERTO PURWOKERTO
2024**

DAFTAR ISI

DAFTAR ISI.....	1
PENDAHULUAN DAN PAPARAN DATA	2
1.1 Masalah yang Ingin Diselesaikan.....	2
1.2 Paparan Dataset	3
1.2.1 Informasi Dataset	3
1.2.2 Satatistik Deskriptif Dataset.....	3
1.2.3 Sumber Dataset	4
1.3 Processing Dataset.....	4
1.4 Mekanisme Pembagian Data Training dan Testing	5
METODE DAN EKSPERIMEN	6
2.1 Metode yang Digunakan	6
2.2 Pengukuran Kinerja yang Digunakan (Matrik Evaluasi)	6
2.3 Setting Parameter yang Digunakan	9
2.4 Eksperimen dan Evaluasi	10
HASIL DAN ANALISIS	13
3.1 Kinerja dan Analisis Tahap Training	13
3.2 Kinerja dan Analisis Tahap Testing	13
KESIMPULAN.....	16

PENDAHULUAN DAN PAPARAN DATA

1.1 Masalah yang Ingin Diselesaikan

Demam Berdarah Dengue (DBD) merupakan penyakit menular yang disebabkan oleh virus dengue yang ditularkan melalui gigitan nyamuk *Aedes aegypti*. Di negara tropis seperti Indonesia, DBD menjadi masalah kesehatan utama, dengan angka kejadian yang terus meningkat. Gejala DBD bisa mirip dengan penyakit lain, sehingga diagnosis dini sering kali terlambat, yang berisiko memperburuk kondisi pasien dan menyebabkan komplikasi serius.

Penyakit DBD memiliki beragam gejala, mulai dari demam ringan, ruam kulit, nyeri otot, hingga perdarahan dan syok dengue yang bisa berujung pada kematian. Diagnosis dini sangat penting untuk mencegah penyakit berkembang ke tahap yang lebih parah. Namun, deteksi dini DBD sering kali sulit dilakukan karena gejala awalnya seringkali mirip dengan penyakit lain, seperti demam tifoid atau influenza. Hal ini menyebabkan banyak pasien terlambat mendapatkan diagnosis yang tepat, sehingga berisiko mengalami komplikasi serius yang membutuhkan penanganan intensif.

Selain gejala klinis, faktor-faktor lain yang mempengaruhi tingkat risiko DBD pada pasien meliputi usia serta faktor lingkungan tempat tinggal, seperti tingkat kepadatan penduduk, kebersihan lingkungan, dan keberadaan tempat perindukan nyamuk. Variabilitas ini membuat identifikasi risiko DBD menjadi lebih kompleks, karena setiap individu dapat memiliki pola risiko yang berbeda berdasarkan kombinasi faktor-faktor tersebut.

Untuk mengatasi hal ini, diperlukan model klasifikasi yang dapat memprediksi risiko DBD secara cepat dan akurat berdasarkan data pasien. Salah satu metode yang dapat digunakan adalah *K-Nearest Neighbors* (KNN), sebuah

algoritma klasifikasi yang mengidentifikasi pola dalam data pasien dengan membandingkan kesamaan gejala dan faktor lainnya. Dengan KNN, model ini dapat memberikan prediksi risiko DBD berdasarkan data medis dan demografis pasien, memungkinkan diagnosis lebih cepat dan pengambilan keputusan yang lebih tepat.

1.2 Paparan Dataset

1.2.1 Informasi Dataset

Dataset yang digunakan berasal dari file `data_dbd.csv`, berisi informasi medis pasien, termasuk gejala yang berkaitan dengan DBD dan hasil tes terkait.

- Jumlah total data: 500
- Jumlah fitur: 5 fitur kesehatan dan demografis.
- Target: Risiko DBD (Rendah/Tinggi/sedang).

1.2.2 Statistik Deskriptif Dataset

1. Umur
 - Rentang: 1-70 Tahun.
 - Rata-rata: 35 Tahun.
2. Jumlah Trombosit
 - Rata-rata: 251088 per mikroliter darah.
 - Rentang: 50.046 - 449.989 per mikroliter darah
3. Suhu Tubuh
 - Rata-rata: 38°C.
 - Rentang: 36 - 40.5°C
4. Ruam Kulit
 - Ya: 49.4%
 - Tidak: 50.6%

5. Nyeri Otot

- Ya: 51.6%
- Tidak: 48.4%

1.2.3 Sumber Dataset

Dataset ini berasal dari pengamatan medis atau hasil survei yang telah dikumpulkan untuk tujuan prediksi risiko DBD.

1.3 Processing Dataset

Tahap pre-processing bertujuan untuk memastikan data siap digunakan dalam pemodelan. Langkah-langkah pre-processing meliputi:

1. Mengatasi Missing Values: Pengecekan kolom dengan nilai kosong (missing values).
2. Encoding Data Kategorikal:

Kolom Ruam Kulit dan Nyeri Otot diubah menjadi format numerik menggunakan:

- 0: Tidak
- 1: Ya

3. Normalisasi Data Numerik: Untuk kolom “Umur”, “Jumlah Trombosit”, dan “Suhu Tubuh” dilakukan normalisasi menggunakan Min-Max Scaling atau Standardization agar memiliki skala yang seragam.
4. Pengecekan Duplikasi: Pengecekan baris duplikat dan penghapusan jika ditemukan.
5. Transformasi Target:

Kolom target (risiko DBD) dikonversi menjadi numerik:

- 0: Rendah

- 1: Sedang
- 2: Tinggi

1.4 Mekanisme Pembagian Data Training dan Testing

Dataset dibagi menjadi data training dan data testing untuk evaluasi performa model klasifikasi:

1) Pembagian Data:

- Training Data: 80% dari total dataset
- Testing Data: 20% dari total dataset

2) Metode Pembagian:

Menggunakan fungsi `train_test_split` dari library `scikit-learn`:

```
# Pisahkan data latih dan data uji
X_train, X_test, y_train, y_test = train_test_split(X, y,
test_size=0.2, random_state=42)
```

Alasan Pembagian:

- Training Data digunakan untuk melatih model.
- Testing Data digunakan untuk menguji performa model pada data baru.
- Random State digunakan untuk memastikan hasil yang konsisten.

METODE DAN EKSPERIMEN

2.1 Metode yang Digunakan

K-Nearest Neighbors (KNN): Algoritma KNN bekerja dengan cara menghitung jarak antara data uji dengan data latih menggunakan ukuran jarak (misalnya Euclidean, Manhattan, dll.). KNN kemudian memilih k tetangga terdekat dan mengklasifikasikan data uji berdasarkan mayoritas label kelas yang ditemukan di antara tetangga-tetangga tersebut.

Keuntungan KNN:

- Mudah dipahami dan diimplementasikan.
- Tidak memerlukan model yang dilatih secara eksplisit (non-parametric).
- Mampu menangani masalah klasifikasi multi-kelas.

Kekurangan KNN:

- Performa bisa menurun pada dataset dengan dimensi yang sangat tinggi (high dimensionality).
- Memerlukan komputasi yang lebih banyak pada saat inferensi, terutama untuk dataset besar.

2.2 Pengukuran Kinerja yang Digunakan (Matrik Evaluasi)

Untuk mengevaluasi performa model KNN dalam memprediksi risiko DBD, kita menggunakan beberapa matrik evaluasi utama:

1) Confusion Matrix

Confusion matrix adalah alat untuk menilai akurasi klasifikasi model dengan membandingkan label yang diprediksi dengan label yang sebenarnya. Matriks ini menggambarkan jumlah prediksi yang benar dan salah untuk setiap kelas.

Komponen dari Confusion Matrix:

- True Positive (TP): Jumlah data yang benar-benar positif (misalnya, prediksi "risiko tinggi" yang memang benar).
- False Positive (FP): Jumlah data yang diprediksi positif padahal seharusnya negatif (misalnya, "risiko tinggi" yang ternyata bukan risiko tinggi).
- True Negative (TN): Jumlah data yang benar-benar negatif (misalnya, prediksi "risiko rendah" yang memang benar).
- False Negative (FN): Jumlah data yang diprediksi negatif padahal seharusnya positif (misalnya, "risiko rendah" yang ternyata seharusnya risiko tinggi).

2) Precision

Precision mengukur akurasi dari prediksi kelas positif (misalnya, ketika model memprediksi risiko DBD "tinggi"). Precision menunjukkan seberapa tepat model dalam mengklasifikasikan kelas positif

$$Precision = \frac{TP}{TP + FP}$$

Interpretasi: Precision yang tinggi menunjukkan bahwa ketika model memprediksi kelas positif, kemungkinan besar itu benar.

3) Recall (Sensitivity)

Recall mengukur kemampuan model untuk mendeteksi semua kasus positif yang sebenarnya (misalnya, mendeteksi semua pasien dengan risiko tinggi). Recall menunjukkan seberapa banyak data positif yang berhasil ditemukan oleh model.

$$Recall = \frac{TP}{TP + FN}$$

Interpretasi: Recall yang tinggi berarti model mampu mendeteksi hampir semua kasus positif, meskipun mungkin ada beberapa prediksi yang salah (false positives).

4) F1-Score

F1-Score adalah rata-rata harmonis antara precision dan recall. F1-Score memberikan gambaran yang lebih seimbang tentang kinerja model, terutama pada dataset yang tidak seimbang.

$$F1 - Score = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

Interpretasi: F1-Score yang tinggi menunjukkan bahwa model memiliki keseimbangan yang baik antara precision dan recall. Ini sangat penting ketika ada trade-off antara keduanya.

5) Akurasi

Akurasi mengukur seberapa sering model memprediksi dengan benar, baik untuk kelas positif maupun negatif. Akurasi dihitung sebagai rasio antara jumlah prediksi yang benar (TP + TN) dan jumlah total data.

$$Akurasi = \frac{TP + TN}{TP + TN + FP + FN}$$

Interpretasi: Akurasi memberikan gambaran umum dari kinerja model, tetapi bisa menyesatkan jika data sangat tidak seimbang (misalnya, jika sebagian besar data adalah kelas negatif).

6) Support

Support adalah jumlah contoh dalam dataset yang sebenarnya berada dalam kelas tertentu. Metrik ini penting untuk memahami distribusi data dalam setiap kelas, terutama jika dataset tidak seimbang.

Interpretasi: Support membantu kita memahami bagaimana model berperforma pada setiap kelas berdasarkan jumlah data yang ada.

7) ROC

ROC (Receiver Operating Characteristic) adalah kurva yang digunakan untuk mengevaluasi performa model klasifikasi biner, terutama dalam konteks klasifikasi dengan probabilitas output. Kurva ROC menggambarkan hubungan antara True Positive Rate (TPR) dan False Positive Rate (FPR) untuk berbagai ambang batas (threshold) dalam memprediksi kelas positif.

$$FPR = \frac{\text{False Positive}}{\text{False Positive} + \text{True Negative}} = \frac{FP}{FP + TN}$$

Interpretasi:

Jika model bekerja sempurna, ROC curve akan berada di pojok kiri atas, dengan $TPR = 1$ dan $FPR = 0$.

Jika model tidak lebih baik daripada tebakan acak, kurva ROC akan mengikuti garis diagonal dari titik (0,0) ke titik (1,1).

2.3 Setting Parameter yang Digunakan

Dalam eksperimen menggunakan KNN, parameter-parameter yang diuji dan disesuaikan adalah sebagai berikut:

1. Nilai K (Jumlah Tetangga Terdekat):

Nilai k menentukan jumlah tetangga terdekat yang digunakan untuk klasifikasi.

- Pada eksperimen ini, nilai k diuji pada beberapa opsi: **3, 5, 7, dan 9**.
- Nilai k yang terlalu kecil dapat menyebabkan *overfitting*, di mana model terlalu sensitif terhadap data latih.

- Nilai k yang terlalu besar dapat menyebabkan *underfitting*, di mana model kurang sensitif terhadap variasi data.

2. Metric Jarak

Metric jarak adalah metode untuk menghitung jarak antara data uji dan data latih. Pada eksperimen ini, diuji beberapa opsi:

- Euclidean: Jarak langsung atau jarak garis lurus.
- Manhattan: Jarak berbasis blok atau jarak sum-of-absolute-differences.
- Chebyshev: Jarak terjauh dalam satu dimensi.

3. Bobot (Weights):

- Uniform: Semua tetangga memiliki bobot yang sama.
- Distance: Tetangga yang lebih dekat memiliki bobot lebih besar.

2.4 Eksperimen dan Evaluasi

Proses Eksperimen

Eksperimen dilakukan dengan menggunakan GridSearchCV, sebuah teknik untuk mencari kombinasi parameter terbaik secara sistematis. Berikut langkah-langkahnya:

1. Definisi Parameter Grid:

Parameter grid mencakup semua kombinasi nilai k , metric jarak, dan bobot.

2. Cross-Validation:

Proses validasi dilakukan dengan skema 5-fold cross-validation, di mana data dibagi menjadi 5 subset. Model dilatih pada 4 subset dan diuji pada 1 subset secara bergantian.

3. Evaluasi Akurasi:

Skor evaluasi didasarkan pada akurasi. Parameter terbaik dipilih berdasarkan skor akurasi tertinggi.

Hasil Eksperimen

Hasil dari GridSearchCV menunjukkan parameter terbaik untuk model KNN:

Parameter Terbaik:

- k: 9
- Bobot: Distance
- Metric: Manhattan
- Akurasi Model: Model KNN dengan parameter terbaik menghasilkan akurasi {accuracy:.2f}.

Evaluasi Performa

1. Classification Report:

Model dievaluasi menggunakan classification report, yang mencakup metrik berikut:

- Precision: Kemampuan model dalam memprediksi kelas positif secara benar.
- Recall: Kemampuan model dalam menangkap semua data aktual dari kelas positif.
- F1-Score: Harmonic mean antara precision dan recall.

Hasil evaluasi menunjukkan performa model untuk setiap kelas.

2. Confusion Matrix:

Confusion matrix digunakan untuk melihat distribusi prediksi model terhadap label sebenarnya. Berikut visualisasi matriks menggunakan heatmap:

- Diagonal (True Positive): Prediksi benar untuk setiap kelas.
- Off-Diagonal (False Positive/False Negative): Kesalahan prediksi.

Confusion matrix menunjukkan bahwa model memiliki distribusi prediksi yang cukup baik.

3. ROC Curve:

Untuk evaluasi multi-class classification, dilakukan perhitungan ROC Curve untuk setiap kelas.

- True Positive Rate (TPR): Kemampuan model dalam mendeteksi positif sebenarnya.
- False Positive Rate (FPR): Kemampuan model dalam menghindari negatif palsu.
- Area Under Curve (AUC): Mengukur kualitas model dalam membedakan antara kelas-kelas.

Hasil menunjukkan bahwa model memiliki AUC yang cukup tinggi untuk setiap kelas, menunjukkan bahwa model mampu memisahkan kelas dengan baik.

HASIL DAN ANALISIS

3.1 Kinerja dan Analisis Tahap Training

Model KNN dilatih menggunakan 80% dari dataset. Fitur-fitur yang digunakan dalam pelatihan meliputi umur, jumlah trombosit, suhu tubuh, ruam kulit, dan nyeri otot. Proses data meliputi encoding label dan normalisasi untuk memastikan fitur berada pada skala yang seragam.

Selama tahap pelatihan, model diuji dengan berbagai kombinasi parameter menggunakan GridSearchCV untuk mencari parameter optimal. Hasilnya, parameter terbaik ditemukan dengan nilai `metric = 'manhattan'`, `n_neighbors = 9`, dan `weights = 'distance'`, yang menghasilkan akurasi sempurna sebesar 100% pada data pelatihan.

Laporan klasifikasi menunjukkan bahwa model memiliki nilai presisi, recall, dan F1-score sebesar 1.00 untuk semua kelas, yaitu Rendah, Sedang, dan Tinggi, dengan akurasi rata-rata tertimbang sebesar 1.00. Hal ini menunjukkan bahwa model memiliki performa yang sangat baik dalam mengenali pola pada data pelatihan.

Berdasarkan matriks kebingungan:

- Model berhasil mengklasifikasikan 70 sampel kelas Rendah dengan benar.
- Model mengklasifikasikan seluruh 159 sampel kelas Sedang dengan benar.
- Model juga mengklasifikasikan seluruh 171 sampel kelas Tinggi dengan benar.

Tidak ada kesalahan klasifikasi (misclassification) yang terjadi, yang menguatkan bahwa model memiliki tingkat akurasi sempurna pada data pelatihan.

3.2 Kinerja dan Analisis Tahap Testing

Setelah tahap pelatihan selesai, model diuji menggunakan 20% data uji yang belum digunakan. Tujuan utama pengujian ini adalah untuk mengevaluasi kemampuan model dalam memprediksi risiko DBD pada data yang belum dikenal.

Pada tahap testing, model dengan $k = 9$ menunjukkan performa terbaik dengan akurasi sebesar 92%. Hal ini menunjukkan bahwa model mampu memprediksi risiko DBD dengan baik berdasarkan fitur-fitur yang ada.

Precision, Recall, dan F1-Score:

- **Precision:**
Rendah: 0.93
Sedang: 0.90
Tinggi: 0.93
- **Recall:**
Rendah: 0.81
Sedang: 0.93
Tinggi: 0.95
- **F1-Score:**
Rendah: 0.87
Sedang: 0.91
Tinggi: 0.94

Dengan rata-rata precision, recall, dan F1-Score di atas 0.85, model menunjukkan kinerja yang seimbang dan andal. Recall yang tinggi pada kelas “Tinggi” sangat penting karena menunjukkan kemampuan model mendeteksi mayoritas data risiko tinggi.

Confusion Matrix:

- **Rendah:**

Prediksi benar: 13, salah (ke kelas “Sedang”): 3.

- **Sedang:**

Prediksi benar: 37, salah (ke kelas “Tinggi”): 3

- **Tinggi:**

Prediksi benar: 42, salah (ke kelas “Sedang”): 1, salah (ke kelas “Rendah”): 1.

Receiver Operating Characteristic (ROC)

- **Rendah:** ROC AUC = 0.99
- **Sedang:** ROC AUC = 0.96
- **Tinggi:** ROC AUC = 0.98

Interpretasi:

- AUC mendekati 1 menunjukkan kemampuan model yang sangat baik dalam membedakan kelas risiko.
- Kelas rendah memiliki AUC tertinggi (0.99), menunjukkan prediksi yang hampir sempurna untuk kelas ini.
- Kinerja AUC untuk kelas sedang (0.96) dan tinggi (0.98) juga sangat baik, menandakan keseimbangan performa model di berbagai kelas risiko.
- Dengan AUC rata-rata 0.967, model ini memiliki performa yang sangat baik dalam mengidentifikasi risiko DBD untuk semua kelas, memperkuat hasil evaluasi lainnya seperti precision, recall, dan F1-score.

KESIMPULAN

Hasil utama yang dapat disimpulkan dari penelitian ini adalah sebagai berikut:

1) Masalah DBD dan Pentingnya Deteksi Dini

DBD merupakan masalah kesehatan utama di negara tropis seperti Indonesia. Gejala awal yang mirip dengan penyakit lain seringkali menghambat diagnosis dini, meningkatkan risiko komplikasi serius. Oleh karena itu, diperlukan model klasifikasi berbasis data medis dan demografis untuk membantu mendeteksi risiko DBD secara cepat dan akurat.

2) Pemrosesan dan Pemilihan Fitur Dataset yang Efektif

Preprocessing dataset dilakukan secara komprehensif, termasuk penanganan missing values, encoding data kategorikal, normalisasi data numerik, dan pembagian dataset menjadi data latih (80%) dan uji (20%). Langkah ini memastikan data siap digunakan untuk pelatihan dan evaluasi model, sementara pemilihan fitur yang tepat membantu meningkatkan akurasi model.

3) Kinerja Model KNN pada Data Latih dan Uji

- Pada data latih, model KNN dengan parameter optimal ($K = 9$, metric = 'manhattan', weights = 'distance') mencapai akurasi sempurna 100%, dengan precision, recall, dan F1-score sebesar 1.00 untuk semua kelas risiko.
- Pada data uji, model menunjukkan performa yang sangat baik dengan akurasi 92%. Precision, recall, dan F1-score rata-rata melebihi 0.85, mengindikasikan keseimbangan dan keandalan dalam mengklasifikasikan risiko DBD.

4) Kemampuan Pemisahan yang Tinggi (ROC dan AUC)

ROC curve untuk setiap kelas risiko menunjukkan AUC mendekati 1, dengan rata-rata 0.967. Hal ini mengindikasikan bahwa model memiliki kemampuan yang sangat baik dalam membedakan antara kelas-kelas risiko berdasarkan fitur input. Secara keseluruhan, model KNN ini sangat efektif untuk digunakan sebagai alat bantu dalam diagnosis dini DBD. Dengan performa yang baik pada berbagai

matrik evaluasi, model ini memiliki potensi untuk membantu dalam pengambilan keputusan medis yang lebih cepat dan akurat, sehingga dapat mengurangi risiko komplikasi serius pada pasien. Implementasi model ini di lingkungan medis dapat meningkatkan efisiensi dalam mendiagnosa dan menangani kasus DBD.